

# Chapitre 3

---

Problèmes quadratiques

Méthodes de Newton locales

Méthodes de descente de gradient

Méthodes quasi-Newton

I

III

**Méthodes d'optimisation sans contrainte**

III



# I) Problèmes quadratiques

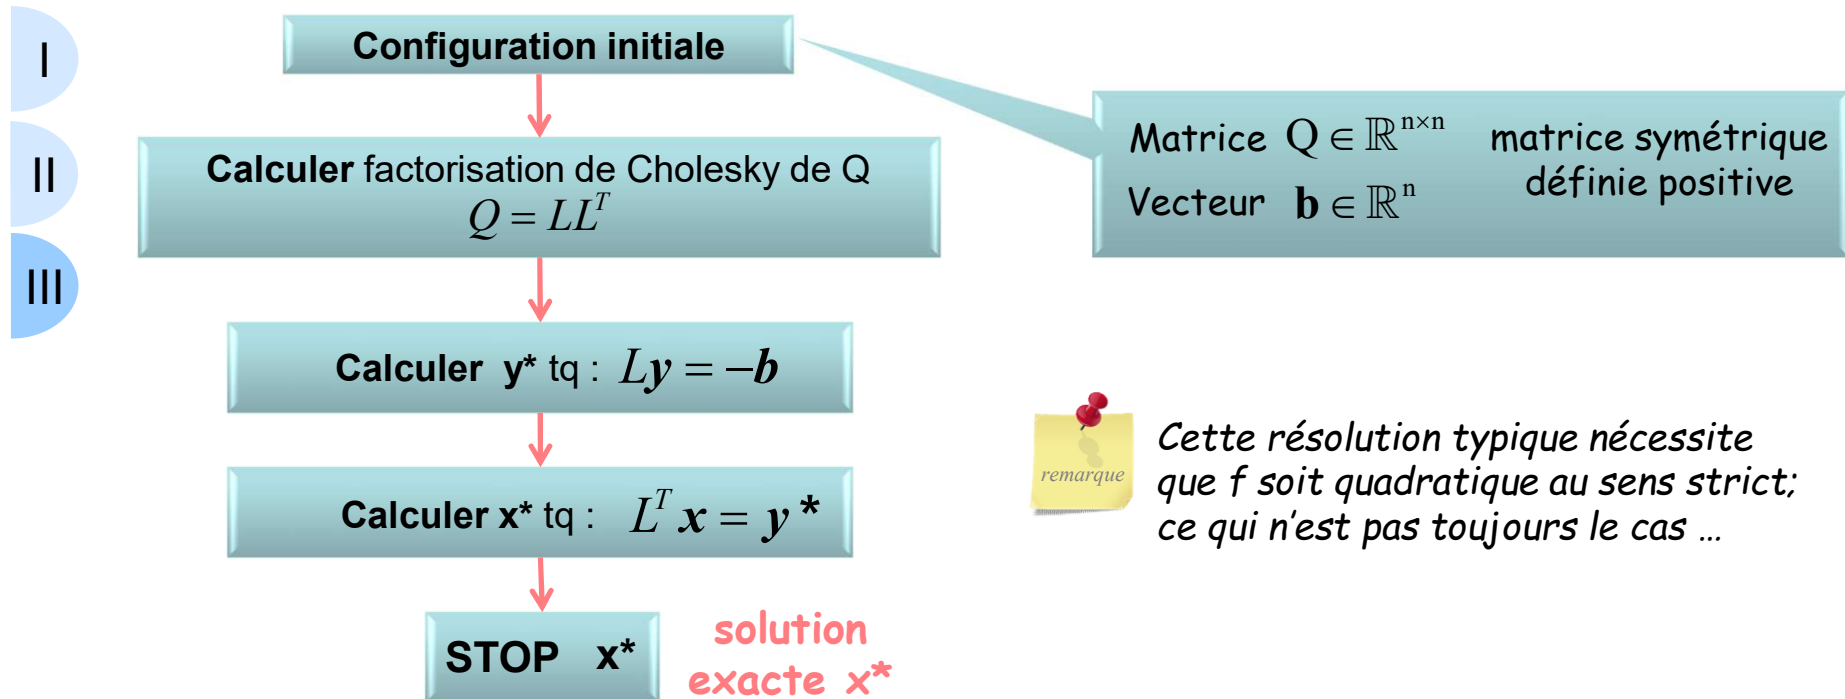
## A) Méthode directe

Considérons le problème d'optimisation suivant :  
(Cf cours Chap 1 T26 et Chap 2 T4)

$\mathbf{b} \in \mathbb{R}^n, c \in \mathbb{R} \quad \mathbf{Q} \in \mathbb{R}^{n \times n}$  matrice symétrique  
définie positive

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$$

Unique minimum global  $\iff \mathbf{Q} \mathbf{x}^* = -\mathbf{b} \implies$  Résolution classique  
(méthode d'algèbre linéaire)



# I) Problèmes quadratiques

## L B) Méthode des gradients conjugués Hestenes et Stiefel (1952)

### → Directions conjuguées

$Q \in \mathbb{R}^{n \times n}$  matrice définie positive

Les vecteurs  $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_k$  non nuls de  $\mathbb{R}^n$  sont dits Q-conjugués si

$$\mathbf{d}_i^T Q \mathbf{d}_j = 0 \quad \forall i, j \text{ tq } i \neq j$$

I

II

III

$\iff \mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_k$  linéairement indépendants

$\iff$  Nombre maximal de direction conjuguées =  $n$



*Si  $Q=I$  les directions conjuguées sont orthogonales*



# I) Problèmes quadratiques

## B) Méthode des gradients conjugués

### → Principe de la méthode

Utilisation de  $n$  directions Q-conjuguées  $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_n$  dans un algorithme basée sur la récurrence suivante :

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k \quad \text{avec} \quad \alpha_k = \arg \min_{\alpha} f(\mathbf{x}_k + \alpha \mathbf{d}_k)$$

$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{n+1}$  : les itérés générés par une méthode de directions conjuguées

I

### → Propriétés:

II

→ pour tout  $k=1, \dots, n$ , le pas  $\alpha_k$  est défini par

$$\alpha_k = -\frac{\mathbf{d}_k^T (\mathbf{Q}\mathbf{x}_k + \mathbf{b})}{\mathbf{d}_k^T \mathbf{Q}\mathbf{d}_k} = -\frac{\mathbf{d}_k^T \nabla f(\mathbf{x}_k)}{\mathbf{d}_k^T \mathbf{Q}\mathbf{d}_k}$$

III

→ pour tout  $k=1, \dots, n$ ,  $\nabla f(\mathbf{x}_k)$  est orthogonal à  $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_{k-1}$


$$\nabla f(\mathbf{x}_k)^T \mathbf{d}_i = 0 \quad \text{pour } i = 1, \dots, k-1$$

→  $\nabla f(\mathbf{x}_{n+1}) = 0$

→ soit  $k$  tq  $\nabla f(\mathbf{x}_k) = 0 \Rightarrow \nabla f(\mathbf{x}_i) = 0$  pour  $i = k, \dots, n+1$

### → Identification du min global en **au plus $n$ itérations**

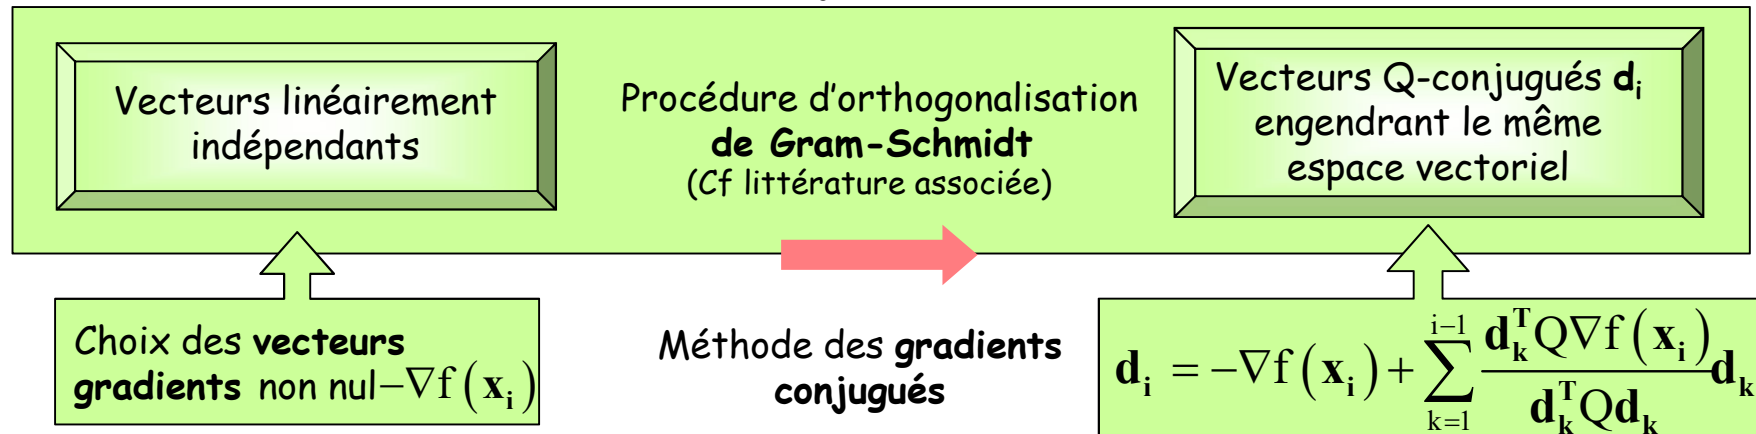
Résolution successives dans des sous espaces vectoriels de dimension croissante engendrés par  $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_i$  ( $i \leq n$ )



# I) Problèmes quadratiques

## B) Méthode des gradients conjugués

→ **Détermination des directions conjugués** (Analogie avec l'orthogonalité)



- I
- II
- III



Les vecteurs gradients sont non seulement indépendant mais ... tous orthogonaux:

$$\nabla f(\mathbf{x}_i)^T \nabla f(\mathbf{x}_k) = 0 \text{ pour } k = 1, \dots, i-1$$

→ Expression de  $\mathbf{d}_i$  en fonction de  $\mathbf{d}_{i-1}$

$$\mathbf{d}_i = -\nabla f(\mathbf{x}_i) + \beta_i \mathbf{d}_{i-1} \quad \text{avec} \quad \beta_i = \frac{\nabla f(\mathbf{x}_i)^T \nabla f(\mathbf{x}_i)}{\nabla f(\mathbf{x}_{i-1})^T \nabla f(\mathbf{x}_{i-1})} = \frac{(\mathbf{Q}\mathbf{x}_i + \mathbf{b})^T (\mathbf{Q}\mathbf{x}_i + \mathbf{b})}{(\mathbf{Q}\mathbf{x}_{i-1} + \mathbf{b})^T (\mathbf{Q}\mathbf{x}_{i-1} + \mathbf{b})}$$



# I) Problèmes quadratiques

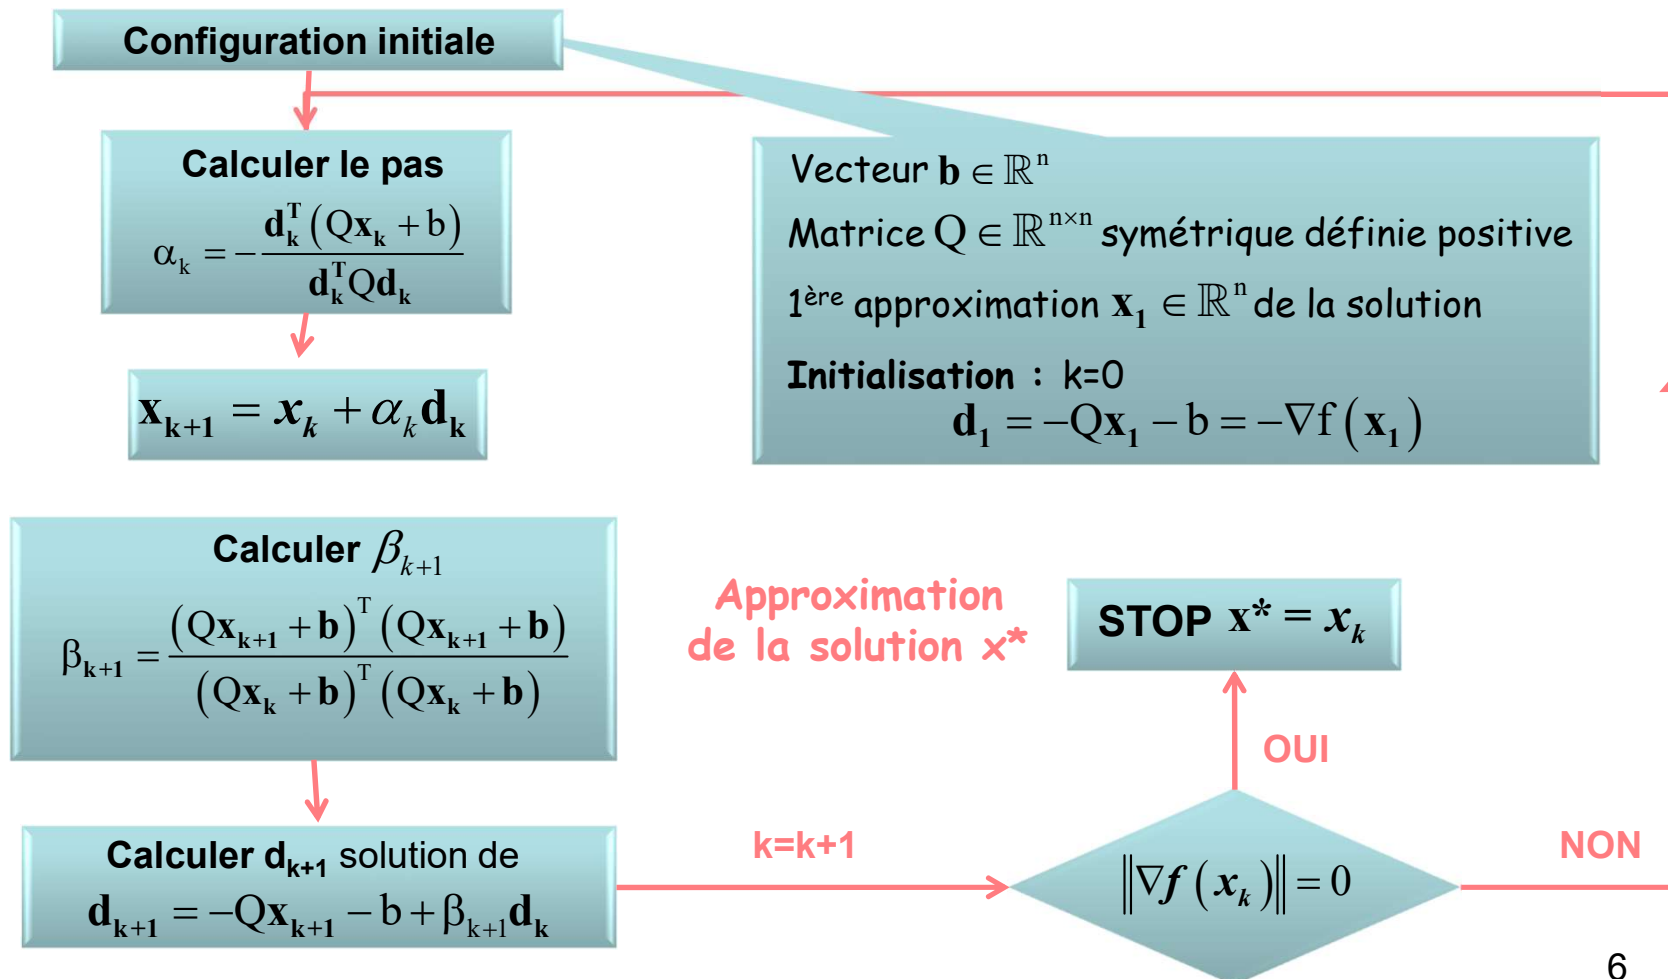
## B) Méthode des gradients conjugués

### → Algorithme



Le critère d'arrêt peut également être:  $k=n+1$

I  
II  
III



## II) Méthode de Newton locale

### A) Méthode de Newton pure

Utilisation de l'algorithme de Newton (cf chap 2 T12)

Résoudre les conditions nécessaires d'optimalité

Trouver une approximation de la solution de l'équation  $\nabla f(\mathbf{x}) = 0$

Algorithme

Configuration initiale

Gradient de  $f$   $\nabla f : \mathbb{R}^n \rightarrow \mathbb{R}^n$

Hessien de  $f$   $\nabla^2 f : \mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$

1<sup>ère</sup> approximation  $\mathbf{x}_0 \in \mathbb{R}^n$  de la solution

Précision demandée:  $\varepsilon \in \mathbb{R}, \varepsilon > 0$

Initialisation :  $k=0$

Calculer  $\mathbf{d}_{k+1}$  solution de  
 $\nabla^2 f(\mathbf{x}_k) \mathbf{d}_k = -\nabla f(\mathbf{x}_k)$

$\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{d}_k$

$\|\nabla f(\mathbf{x}_k)\| \leq \varepsilon$

NON

OUI

STOP  $\mathbf{x}^* \simeq \mathbf{x}_k$

Approximation de la solution  $\mathbf{x}^*$



Ici, la fonction  $f$  du chap 2 est  $\nabla f(\mathbf{x})$

I  
II  
III



## II) Méthode de Newton locale

### A) Méthode de Newton pure

#### → Avantages / Inconvénients

➤ Méthode converge q-quadratiquement dans les conditions favorables (cf chap 2 T10)

➤ Peut diverger si le point de départ est trop éloigné de la solution

I ➤ **Méthode non définie si  $\nabla^2 f(x_k)$  non inversible** → **Solution** : rendre inversible cette matrice

II ➤ Aucun mécanisme permettant de discerner les minima, des maxima et points selles...

III Globalement, ne peut être utilisée telle quelle dans les problème d'optimisation

Cas favorables

Mise à profit de sa grande efficacité et rapidité de convergence lorsque le cas est adéquat

↔ **Méthode de Newton quadratique (cf T9)**

Autres cas...

Utilisation de méthodes alternatives

↔ **Méthode de Newton avec recherche linéaire (cf T20)**





## II) Méthode de Newton locale

### B) Méthode de Newton quadratique

**Idée de base de la méthode de Newton**

Remplacer une fonction non linéaire par un modèle plus simple

**(i)** Par exemple linéaire (cf Chap 2 T6)

→ **Modèle quadratique**

Application de la formule de Taylor sur une fonction non linéaire

→ **Fonction à plusieurs variables** Soit une fonction  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  deux fois différentiable (cf Chap 2 T6)

Modèle quadratique de  $f$  en  $\hat{\mathbf{x}}$  est noté  $m_{\hat{\mathbf{x}}}(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$  défini par :

$$m_{\hat{\mathbf{x}}}(\mathbf{x}) = f(\hat{\mathbf{x}}) + (\mathbf{x} - \hat{\mathbf{x}})^T \nabla f(\hat{\mathbf{x}}) + \frac{1}{2} (\mathbf{x} - \hat{\mathbf{x}})^T \nabla^2 f(\hat{\mathbf{x}}) (\mathbf{x} - \hat{\mathbf{x}}) \quad \text{En posant : } \mathbf{d} = \mathbf{x} - \hat{\mathbf{x}}$$

$$m_{\hat{\mathbf{x}}}(\hat{\mathbf{x}} + \mathbf{d}) = f(\hat{\mathbf{x}}) + \mathbf{d}^T \nabla f(\hat{\mathbf{x}}) + \frac{1}{2} \mathbf{d}^T \nabla^2 f(\hat{\mathbf{x}}) \mathbf{d}$$



remarque

On retrouve bien la définition d'une forme quadratique (cf chap1 T26) avec  $Q = \nabla^2 f(\hat{\mathbf{x}})$ ,  $\mathbf{b} = \nabla f(\hat{\mathbf{x}})$  et  $c = f(\hat{\mathbf{x}})$



## II) Méthode de Newton locale

### B) Méthode de Newton quadratique

#### Principe

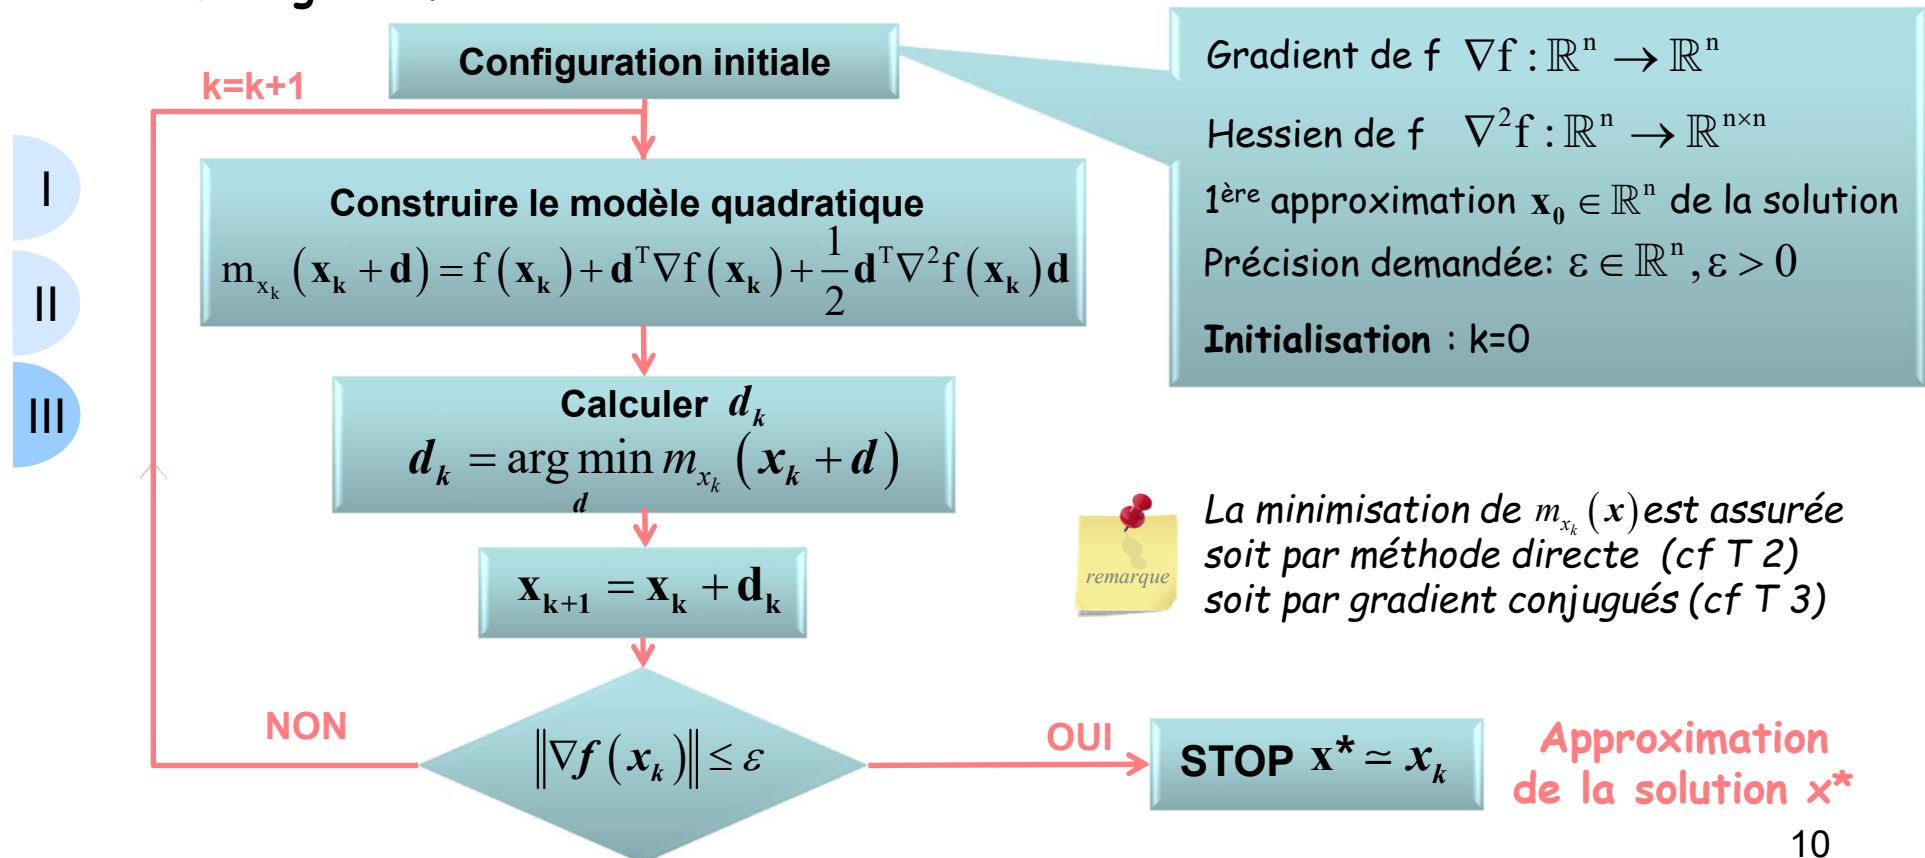
Modélisation quadratique de la fonction objectif en  $x_k$



Condition favorable pour l'efficacité de la méthode de Newton

$\nabla^2 f(x)$  doit forcément être définie positive pour pouvoir appliquer la méthode


#### Algorithme



## II) Méthode de Newton locale

### B) Méthode de Newton quadratique

#### → Limitation



→  $f(x_{k+1}) > f(x_k)$


Nouveau point généré est moins bon que le précédent !!!

I

II

III

Méthode efficace si la fonction est par nature très proche d'une forme quadratique et convexe



→  $f(x_{k+1}) > f(x_k)$

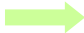

Effet inverse !!! maximisation

Modèle concave non borné

## II) Méthode de Newton locale

### C) Points particuliers

Soit une fonction  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  deux fois différentiable et soit  $\mathbf{x}_k \in \mathbb{R}^n$

 **Point de Newton**  
 *remarque*  
Point obtenu lors d'une itération de la méthode de Newton locale

Point qui minimise le modèle quadratique de la fonction en  $\mathbf{x}_k$

si  $\nabla^2 f(\mathbf{x}_k)$  est définie positive, le point de Newton de  $f$  en  $\mathbf{x}_k$  est le point :

I  $\mathbf{x}_N = \mathbf{x}_k + \mathbf{d}_N$  où  $\mathbf{d}_N$  est la solution du système de Newton suivant:  $\nabla^2 f(\mathbf{x}_k) \mathbf{d}_N = -\nabla f(\mathbf{x}_k)$

II

III  **Point de Cauchy**

Point qui minimise le modèle quadratique dans la direction de la plus forte pente

Le point de Cauchy de  $f$  en  $\mathbf{x}_k$  est le point:  $\mathbf{x}_C = \mathbf{x}_k - \alpha_C \nabla f(\mathbf{x}_k)$  où  $\alpha_C = \arg \min_{\alpha \in \mathbb{R}_0^+} m_{\mathbf{x}_k}(\mathbf{x}_k - \alpha \nabla f(\mathbf{x}_k))$

Si  $f$  est convexe dans la direction du gradient, on a (cf T9):

$$\alpha_C = \frac{\nabla f(\mathbf{x}_k)^T \nabla f(\mathbf{x}_k)}{\nabla f(\mathbf{x}_k)^T \nabla^2 f(\mathbf{x}_k) \nabla f(\mathbf{x}_k)}$$

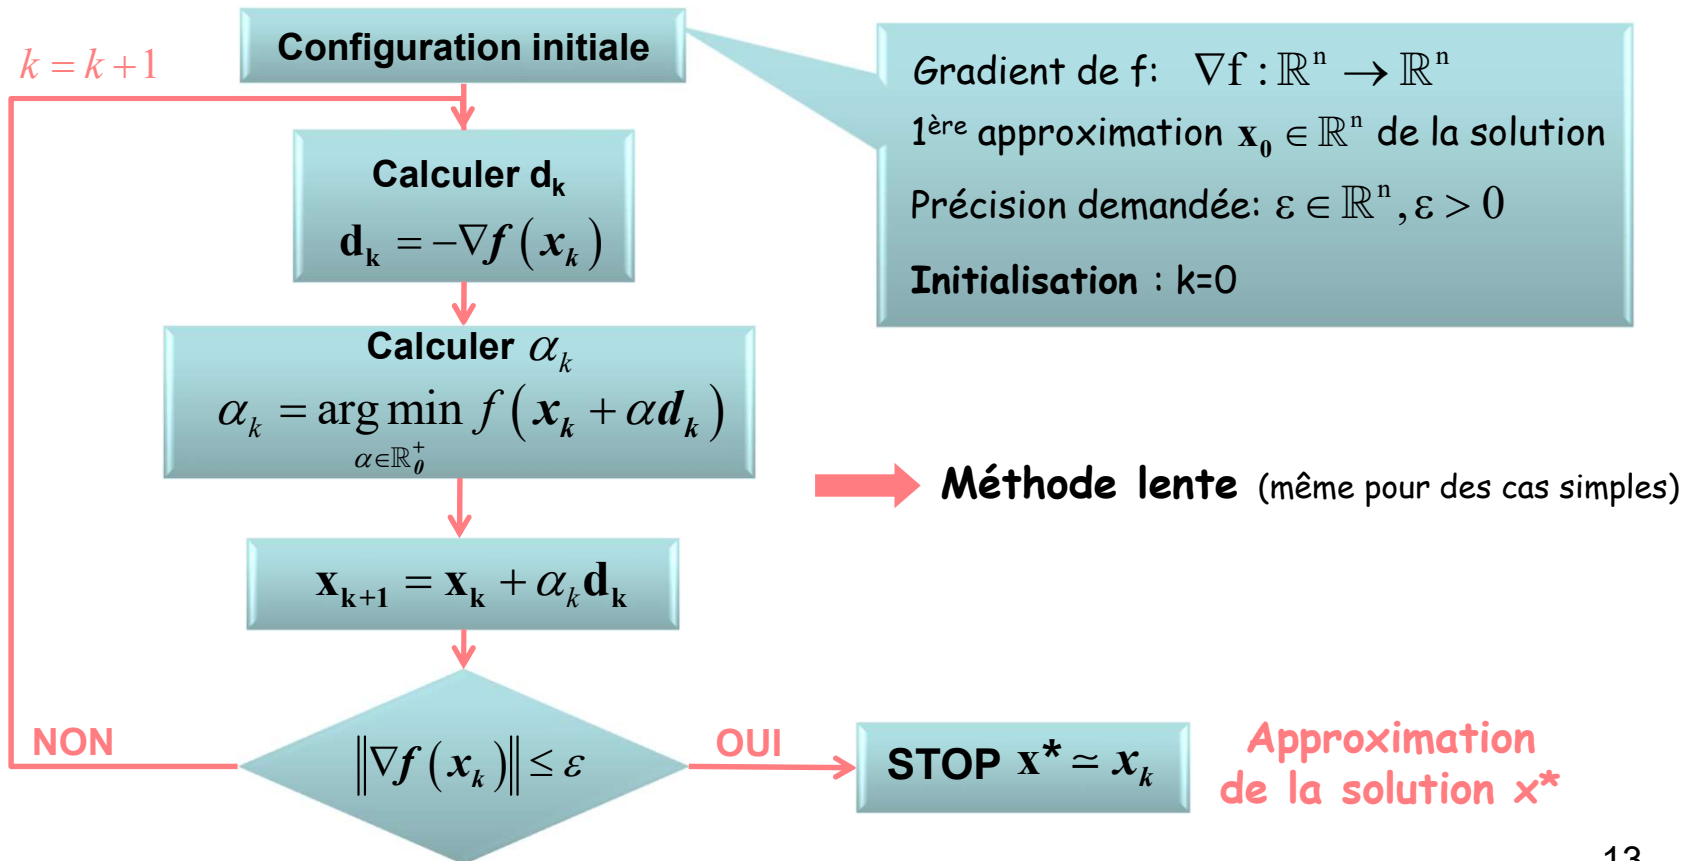


### III) Méthode de la plus forte pente (steepest descent)

#### A) Principe de la méthode

**Idée de base des méthodes de descente**


Suivre la direction de la plus forte pente donnée par la direction opposée au gradient  
(Cf chap 1 T19)



### III) Méthode de la plus forte pente (steepest descent)

#### B) Préconditionnement

Réduction du conditionnement  
(cf Chap 1 T27)



Amélioration des performances de  
l'algorithme des plus fortes pentes

#### → Modification de la direction de descente

Soit  $H_k$  une matrice symétrique définie positive telle que :  $H_k = L_k L_k^T$   
définissant le **changement de variable** pour l'itération  $k$ :  $\mathbf{x}' = L_k^T \mathbf{x}$



Ici,  $H_k$  n'est pas forcément la matrice Hessienne  
mais une matrice permettant la réduction de  $\kappa_2$

#### → Ecriture de la méthode des plus fortes pentes

sur les variables  $\mathbf{x}'$ :  $\mathbf{x}'_{k+1} = \mathbf{x}'_k - \alpha_k \nabla \tilde{f}(\mathbf{x}'_k)$

sur les variables  $\mathbf{x}$ :  $\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k H_k^{-1} \nabla f(\mathbf{x}_k)$

on pose

$$D_k = H_k^{-1}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k D_k \nabla f(\mathbf{x}_k)$$

#### → Direction de descente à chaque itération:

$$\mathbf{d}_k = -D_k \nabla f(\mathbf{x}_k)$$



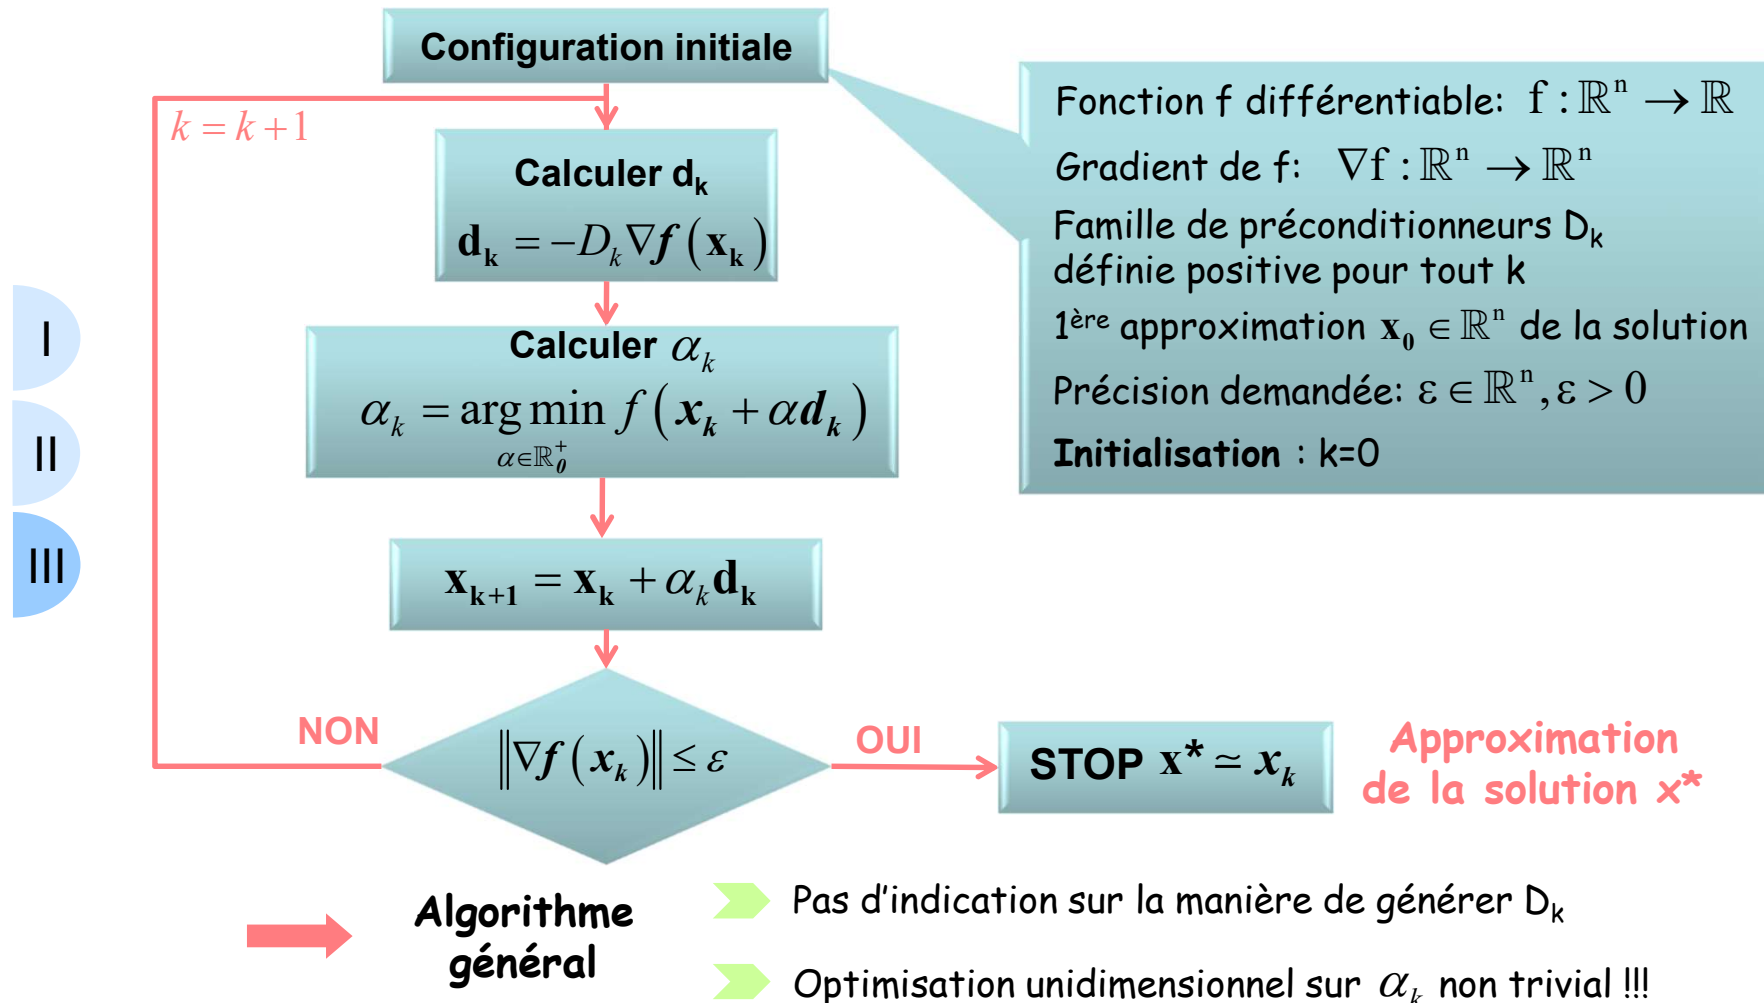
$D_k$  permet de preconditionner  
différemment à chaque itération  $k$



### III) Méthode de la plus forte pente (steepest descent)

#### B) Préconditionnement

#### ➡ Algorithme avec preconditionnement



### III) Méthode de la plus forte pente (steepest descent)


#### B) Préconditionnement

##### Exemple

Minimum de la fonction

$$f(\mathbf{x}) = \frac{1}{2}x_1^2 + \frac{9}{2}x_2^2$$

Descente en « zig zag »  
caractéristique de la méthode



I



→ Lenteur désastreuse !!!

II


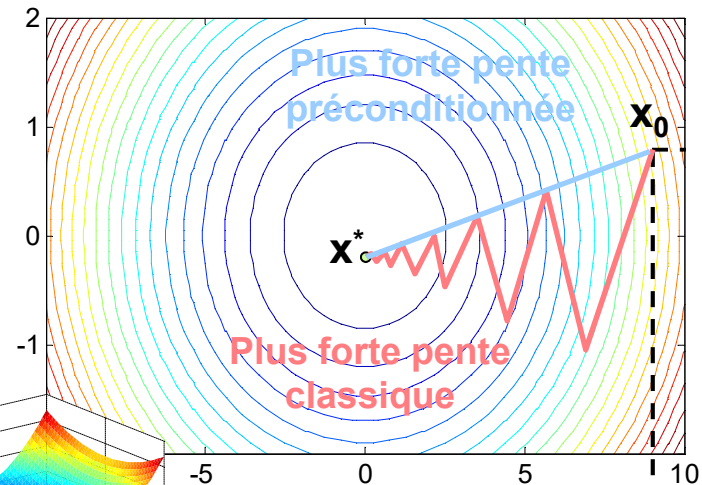
Préconditionnement par factorisation de  
Cholesky de la matrice Hessienne

III



→ Le minimum est  
atteint au bout ...d'une  
seule itération !!!

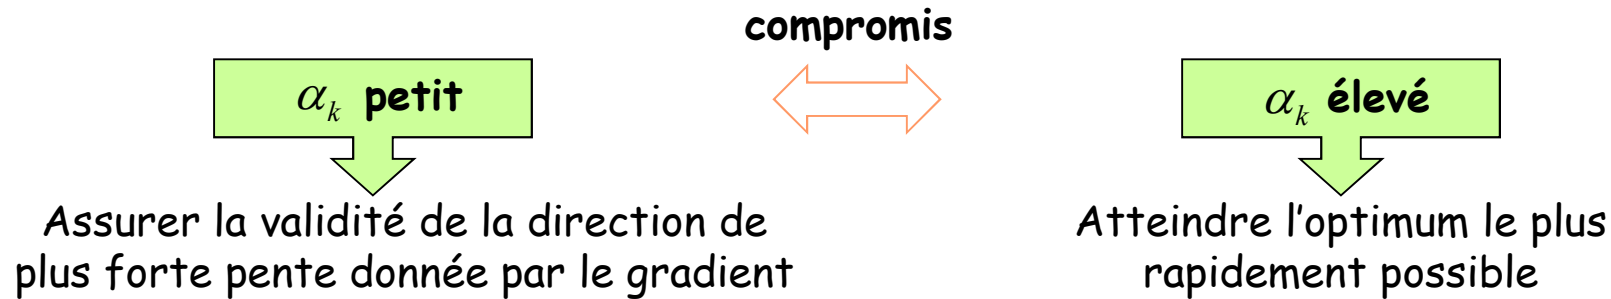
Amélioration significative lorsque la fonction  
objectif est preconditionnée





### III) Méthode de la plus forte pente (steepest descent)

↳ C) Choix du pas



- I →  $\alpha_k$  **pas trop grand** Eviter la disproportion entre la longueur du pas et la diminution de la fonction objectif résultante
- II
- III

$$\gamma = -\beta_1 \nabla f(\mathbf{x}_k)^T \mathbf{d}_k$$


$$0 < \beta_1 < 1$$

Choix de  $\gamma$  en fonction de la pente en  $\mathbf{x}_k$  dans la direction  $\mathbf{d}_k$

$$f(\mathbf{x}_k) - f(\mathbf{x}_k + \alpha_k \mathbf{d}_k) \geq \alpha_k \gamma$$

**1<sup>ère</sup> condition de Wolfe (CW1)**

$$f(\mathbf{x}_k + \alpha_k \mathbf{d}_k) \leq f(\mathbf{x}_k) - \alpha_k \gamma$$



Diminution jugée suffisante pour  $\alpha \leq 2$



### III) Méthode de la plus forte pente (steepest descent)

#### C) Choix du pas

→  $\alpha_k$  pas trop petit

Eviter la dégénérescence  
des pas  $\alpha_k$  vers 0

Notion de « progrès  
suffisant »



Progrès suffisant si dérivée directionnelle au point  $\mathbf{x}_k + \alpha_k \mathbf{d}_k$   
augmente par rapport à celle évaluée point  $\mathbf{x}_k$


$$\nabla f(\mathbf{x}_k + \alpha_k \mathbf{d}_k)^T \mathbf{d}_k \geq \beta_2 \nabla f(\mathbf{x}_k)^T \mathbf{d}_k \quad \text{avec} \quad \nabla f(\mathbf{x}_k)^T \mathbf{d}_k < 0$$

$$\frac{\nabla f(\mathbf{x}_k + \alpha_k \mathbf{d}_k)^T \mathbf{d}_k}{\nabla f(\mathbf{x}_k)^T \mathbf{d}_k} \leq \beta_2$$

$$0 < \beta_2 < 1$$

2<sup>de</sup> condition de Wolfe (CW2)

$$\frac{\nabla f(\mathbf{x}_k + \alpha_k \mathbf{d}_k)^T \mathbf{d}_k}{\nabla f(\mathbf{x}_k)^T \mathbf{d}_k}$$



Progrès jugé suffisante pour  $\alpha \geq 1,5$



Ces conditions portent également de  
nom de condition d'Armijo-Goldstein

La validité des conditions  
de Wolfe impose que:


$$0 < \beta_1 < \beta_2 < 1$$



### III) Méthode de la plus forte pente (steepest descent)

#### C) Choix du pas

➔ **Algorithme de Fletcher et Lemaréchal (FL)** Recherche linéaire du pas qui vérifie les conditions de Wolfe



La quantité  $+\infty$  est représenté numériquement par un nb suffisamment grand




## IV) Méthode de Newton avec recherche linéaire

### A) Principe général

Combinaison de 2 méthodes

Méthode de Newton  
(cf T7)



Méthode de plus forte pente  
préconditionnée  
(cf T15)

Itération k

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \nabla^2 f(\mathbf{x}_k)^{-1} \nabla f(\mathbf{x}_k)$$

Itération k

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k D_k \nabla f(\mathbf{x}_k)$$

$D_k$  défini positive



Souvent en échec



Converge rapidement



fonctionnelle



lente

I

II

III



## IV) Méthode de Newton avec recherche linéaire

### A) Principe général

Application de l'itération de la méthode des plus fortes pentes préconditionnée

➤ Si  $\left\{ \begin{array}{l} \nabla^2 f(\mathbf{x}_k) \text{ est défini positif} \\ \alpha_k = 1 \text{ vérifie les CW} \end{array} \right.$  ➔ Itérations équivalentes

$$D_k = \nabla^2 f(\mathbf{x}_k)^{-1}$$

I ➤ Si  $\alpha_k = 1$  ne vérifie les CW ➔ Trouver un autre pas

II Application de l'algorithme de Fletcher et Lemaréchal (FL)

III ➤ Si  $\nabla^2 f(\mathbf{x}_k)$  n'est pas défini positif ➔ Trouver un autre préconditionneur

Plusieurs méthodes...



Exemple

$D_k$  diagonale avec pour élément (i,i)  $\max \left( \varepsilon, \left( \frac{\partial^2 f}{\partial x_i^2}(\mathbf{x}_k) \right)^{-1} \right)$   
avec  $\varepsilon > 0$  pour garantir l'aspect définie positive



## IV) Méthode de Newton avec recherche linéaire

### B) Méthode complète

#### Principe

Application de l'itération de la méthode des plus fortes pentes préconditionnée



*Il existe toujours un  $\tau$  tel que  $D_k$  soit définie positive*

Choix du préconditionneur

Modifier la matrice Hessienne afin de la rendre définie positive

$$D_k = (\nabla^2 f(\mathbf{x}_k) + \tau I)^{-1}$$

#### Recherche de $\tau$ par une méthode simple

Permettant également la factorisation de Cholesky modifiée de  $\nabla^2 f(\mathbf{x}_k) + \tau I$

Norme de Frobenius

$$A \in \mathbb{R}^{m \times n} \quad \|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}$$

Matrice symétrique  $H \in \mathbb{R}^{n \times n}$   
Initialisation :  $k=0$ ,  
si  $\min h_{ii} > 0$  alors  $\tau_0 = 0$   
sinon  $\tau_0 = \|H\|_F$

Configuration initiale

Factorisation de Cholesky  
 $LL^T$  de  $H + \tau_k I$

factorisation  
réussie ?

$$\tau_{k+1} = \max\left(2\tau_k, \frac{1}{2}\|H\|_F\right)$$

$k = k + 1$

STOP  $L$  et  $\tau$



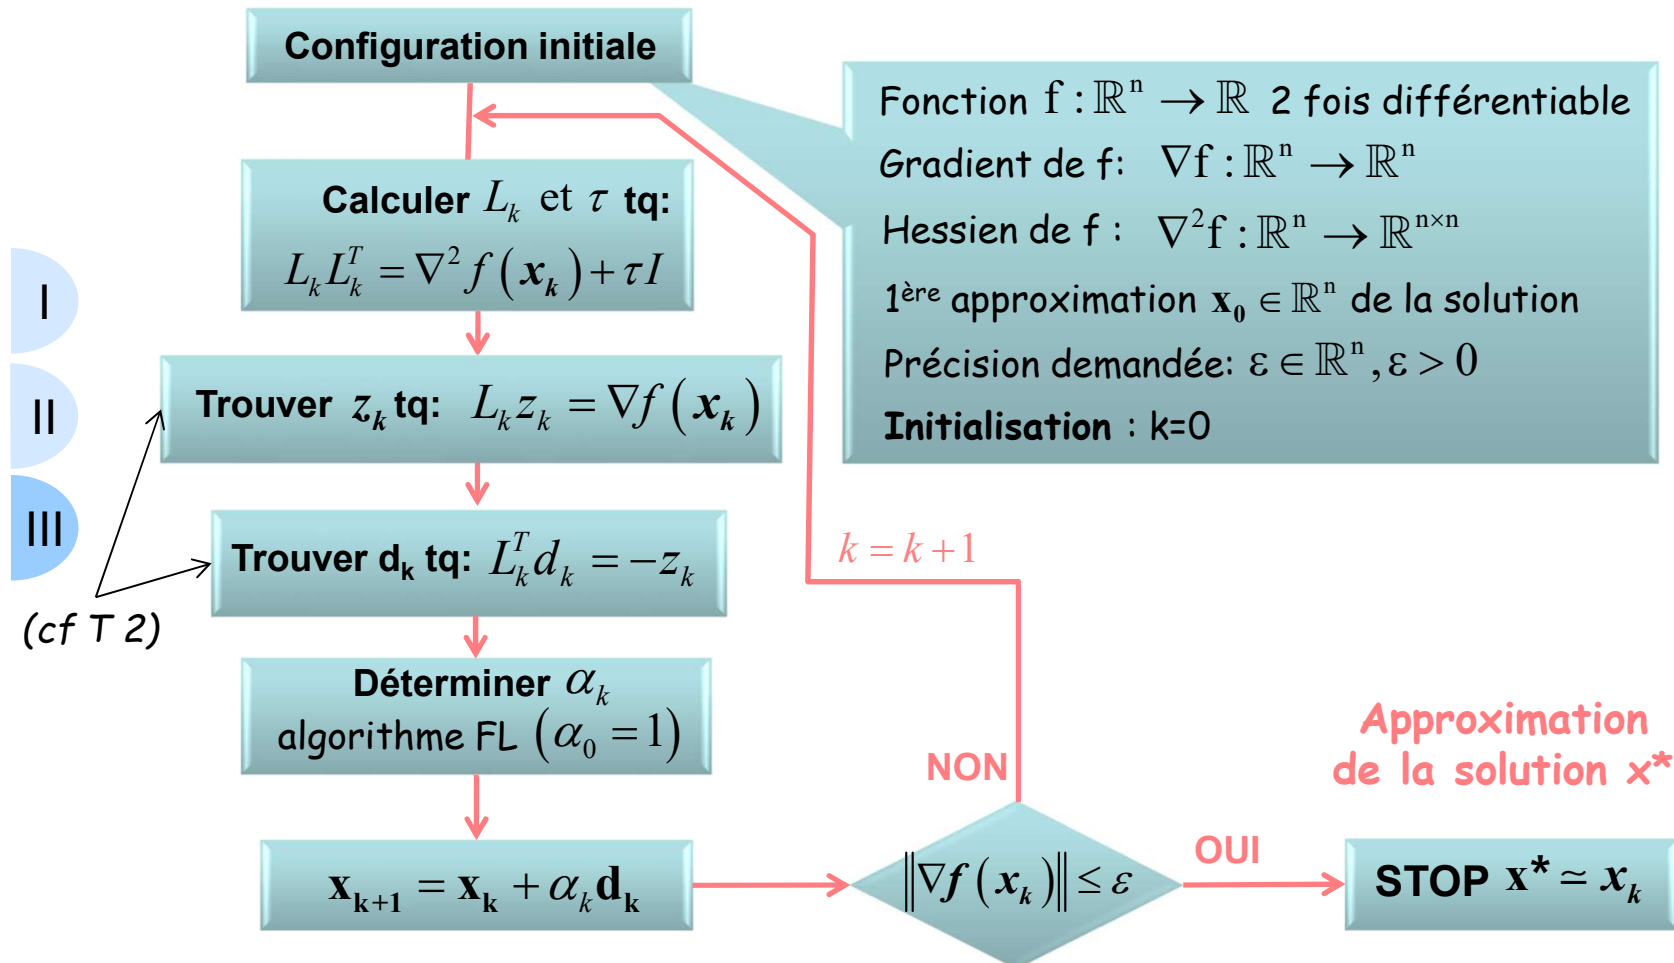
## IV) Méthode de Newton avec recherche linéaire

### B) Méthode complète

#### Algorithme



Lorsque cette méthode est appliquée sur un problème de moindres carrés, elle porte le nom de **Levenberg Marquardt**



## IV) Méthode de Newton avec recherche linéaire

### C) Convergence

Convergence de la  
méthode de Newton

Dépendance du point de départ  
Plus la fonction est non linéaire plus  $x_0$   
doit être proche de la solution  
(cf chapitre 2 T11)

Intérêt de la méthode de  
Newton avec recherche linéaire

Convergence quelque  
soit le point de départ

→ Convergence globale

Soit un algorithme itératif qui génère une suite  $(x_k)_k$  dans  $\mathbb{R}^n$ , afin de résoudre le problème de minimisation sans contrainte :

$$\min_{x \in \mathbb{R}^n} f(x)$$

avec  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  une fonction continûment différentiable.

L'algorithme est dit globalement convergent si:

$$\lim_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0 \quad \forall x_0 \in \mathbb{R}^n$$





## IV) Méthode de Newton avec recherche linéaire

### C) Convergence



Attention à ne pas confondre « convergence globale » avec « minimum global »

Convergence globale  
Pour un algorithme utilisant méthode de Newton avec recherche linéaire

Directions de descente de plus en plus orthogonales à la direction du gradient  
(non démontré ici)

I

II

III

Pour garantir :  $\lim_k \nabla f(\mathbf{x}_k)^T \mathbf{d}_k < 0$



$$\cos \theta_k = \frac{\nabla f(\mathbf{x}_k)^T \mathbf{d}_k}{\|\nabla f(\mathbf{x}_k)\| \|\mathbf{d}_k\|}$$

ne peut pas tendre vers 0 !!!

$\cos \theta_k$  est borné par une constante strictement positive



Les directions  $\mathbf{d}_k$  ne dégénèrent pas en devenant asymptotiquement orthogonales au gradient

On dit que la suite  $(\mathbf{d}_k)_k$  doit être en **relation gradient** avec  $(\mathbf{x}_k)_k$  pour assurer la **convergence globale**



## V) Méthodes de Quasi-Newton

### A) Principe

Même principe que pour la résolution numérique des équations non linéaires

(cf chapitre 2 T16)

Méthode de Newton  
(locale et avec recherche  
linéaire)

Calcul de matrice Hessienne

En pratique:

➤ Calcul analytique et implémentation fastidieux

➔ Sujet à erreurs

➤ Consomme beaucoup de temps de calcul

➔ Pénalise l'efficacité de la méthode

Inspiration directe des  
méthodes sécantes appliquées  
au modèle quadratique

$$H_k \mathbf{d}_{k-1} = \mathbf{y}_{k-1} \quad \text{avec} \\ \mathbf{y}_{k-1} = \nabla f(\mathbf{x}_k) - \nabla f(\mathbf{x}_{k-1})$$

Mise à jour de Broyden  
de la matrice Hessienne  
(cf chapitre 2 T20)



Problème !!!

$\nabla^2 f(\mathbf{x}_k)$  pas forcément  
symétrique ni définie positive

Condition nécessaire pour  
calculer  $\mathbf{d}_k$   
(cf T10)



## V) Méthodes de Quasi-Newton

### B) Méthode BFGS

#### → Modification de la mise à jour de Broyden

BUT: obtenir  $H_k = A_k A_k^T$   
symétrique positive vérifiant l'équation sécante  $\rightarrow A_k A_k^T d_{k-1} = y_{k-1}$



L'équation sécante définie positive possède une solution ssi  $d_{k-1}^T y_{k-1} > 0$

I  
II Soit une fonction  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  différentiable et 2 itérés  $x_k$  et  $x_{k-1}$  tq  $d_{k-1}^T y_{k-1} > 0$

avec  $d_{k-1} = x_k - x_{k-1}$  et  $y_{k-1} = \nabla f(x_k) - \nabla f(x_{k-1})$

III Soit une matrice symétrique définie positive  $H_{k-1} \in \mathbb{R}^{n \times n}$

La mise à jour de Broyden, Fletcher Goldfarb et Shanno (BFGS) est définie par:

$$H_k = H_{k-1} + \frac{y_{k-1} y_{k-1}^T}{y_{k-1}^T d_{k-1}} - \frac{H_{k-1} d_{k-1} d_{k-1}^T H_{k-1}}{d_{k-1}^T H_{k-1} d_{k-1}}$$



## V) Méthodes de Quasi-Newton

### B) Méthode BFGS

#### → Algorithme

Reprendre algorithme de Newton avec recherche linéaire (Cf T23)

→ Remplacement de la matrice Hessienne par son approximation BFGS

$$\nabla^2 f(\mathbf{x}_k) \longleftrightarrow H_k$$

→  $H_k$  forcément définie positive



Simplification de l'algorithme pour la recherche de  $\mathbf{d}_k$

$$H_k \mathbf{d}_k = -\nabla f(\mathbf{x}_k)$$

→ Résolution du système sur  $\mathbf{d}_k$  fastidieux et coûteux en calcul



Calcul analytique de  $H_k^{-1}$

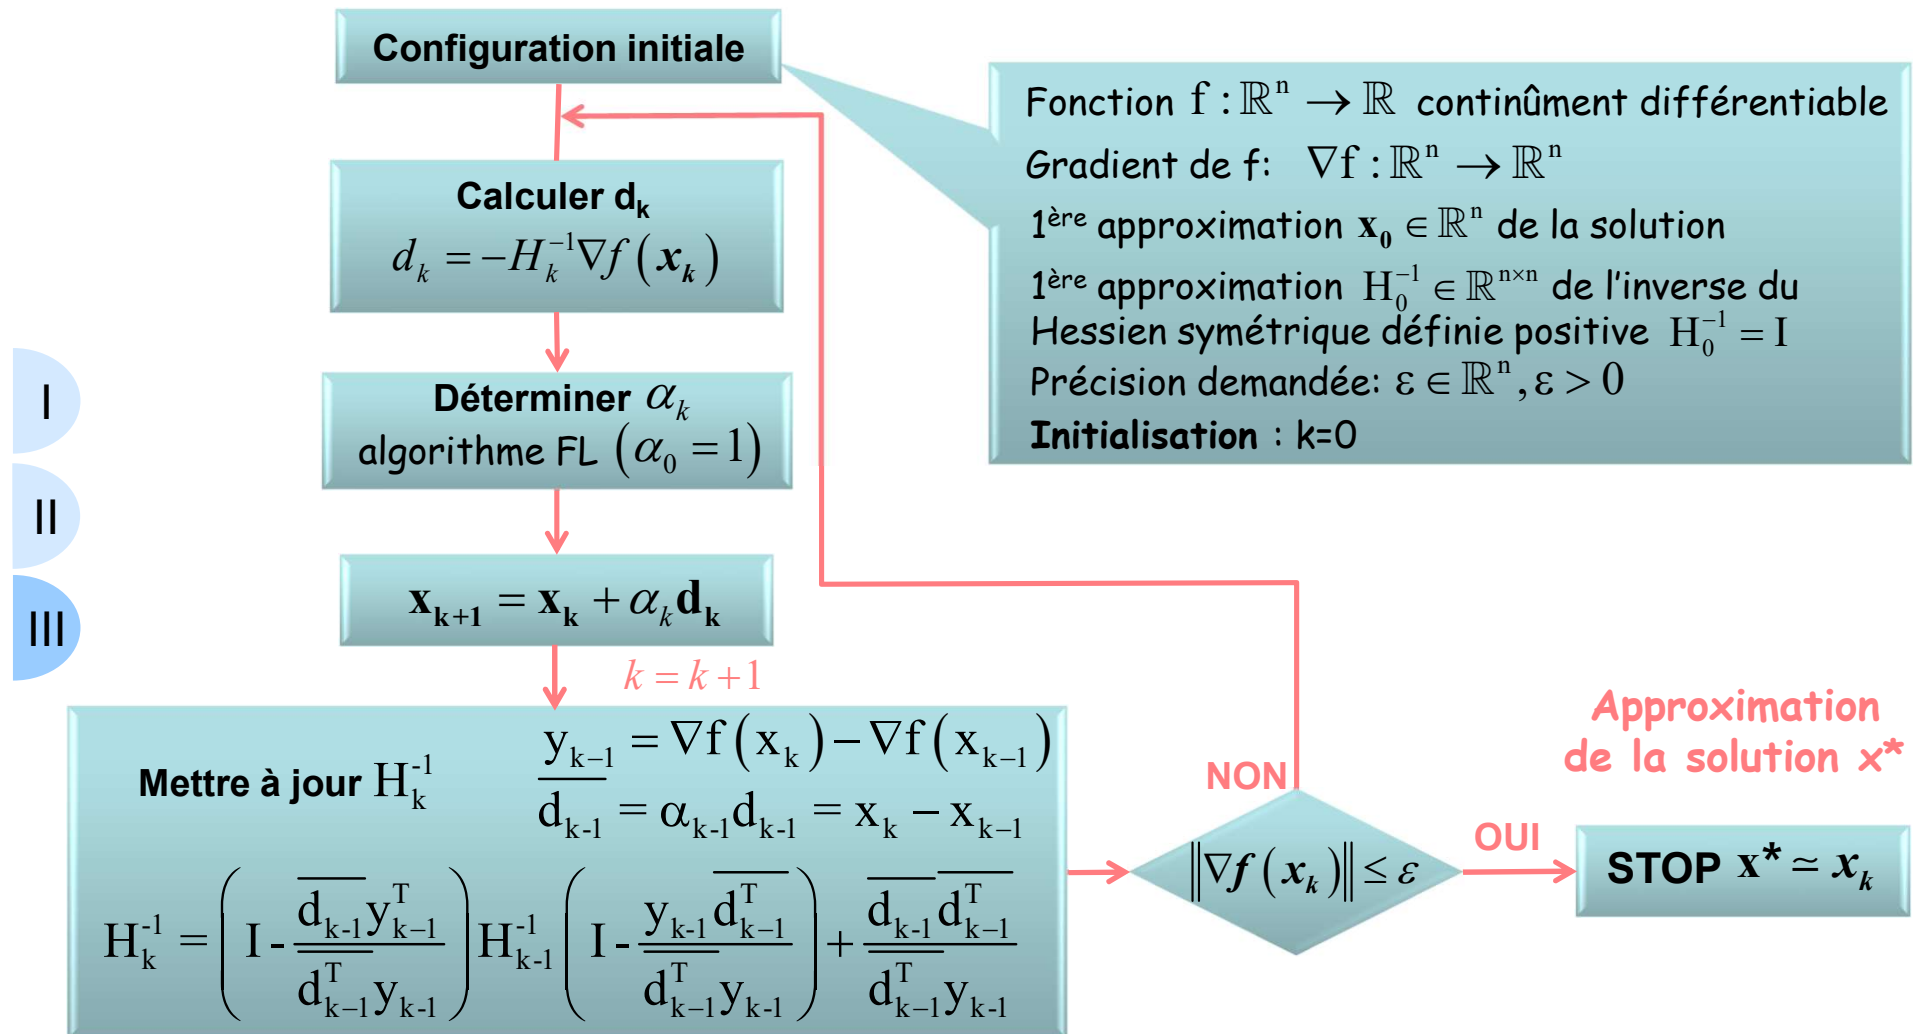
$$\mathbf{d}_k = -H_k^{-1} \nabla f(\mathbf{x}_k) \quad \text{avec} \quad H_k^{-1} = \left( I - \frac{\mathbf{d}_{k-1} \mathbf{y}_{k-1}^T}{\mathbf{d}_{k-1}^T \mathbf{y}_{k-1}} \right) H_{k-1}^{-1} \left( I - \frac{\mathbf{y}_{k-1} \mathbf{d}_{k-1}^T}{\mathbf{d}_{k-1}^T \mathbf{y}_{k-1}} \right) + \frac{\mathbf{d}_{k-1} \mathbf{d}_{k-1}^T}{\mathbf{d}_{k-1}^T \mathbf{y}_{k-1}}$$

Démonstration en appliquant la formule de Sherman-Morrison-Woodbury à  $H_k$



## V) Méthodes de Quasi-Newton

### B) Méthode BFGS



## V) Méthodes de Quasi-Newton

└ C) Autres méthodes ...

Autres formules de mise  
à jour pour la matrice  
Hessienne

Autres méthodes de  
Quasi-Newton

➤ BFGS = mise à jour de rang 2  $\longleftrightarrow (H_k - H_{k-1})$  Matrice de rang 2

➔ Mise à jour symétrique de rang 1 (SR1)

$$H_k = H_{k-1} \pm vv^T \quad \text{où } v \in \mathbb{R}^n$$



*SR1 ne génère pas forcément une matrice  
définie positive même si  $H_{k-1}$  l'est!!!*

**Rang d'une matrice A**

$\text{rang}(A)$  est la dim du sous espace  
 $\text{Im}(A) = \{y \in \mathbb{R}^m \mid \exists x \in \mathbb{R}^n \text{ tq } y = Ax\}$

$A \in \mathbb{R}^{m \times n}$  Nb de valeurs singulières  
non nulles de A

➤ Mise à jour de Davidon étudiée par Fletcher et Powell (DFP)

➤ Etc...

